POLITECNICO DI BARI

DIPARTIMENTO DI INGEGNERIA ELETTRICA E DELL'INFORMAZIONE

Corso di Laurea Magistrale in Ingegneria Informatica
Artificial Intelligence and Data Science

Tema d'Anno in Image Processing

Segmentazione di Tumori Cerebrali in Immagini MRI: Analisi Comparativa tra Approccio Monomodale e Multimodale

Docente
Prof. Ing. Andrea Guerriero

Studente
Roberto Carriero

Anno Accademico 2025/2026

Abstract

La segmentazione automatica dei tumori cerebrali in immagini di risonanza magnetica rappresenta un problema di grande interesse, poiché riduce la necessità di annotare manualmente le lesioni e velocizza le diagnosi. In questo lavoro viene proposta e sviluppata in ambiente MATLAB una pipeline di segmentazione basata su tecniche classiche di *Image Processing*, con l'obiettivo di confrontare l'efficacia di approcci monomodali e multimodali.

La metodologia integra una fase preliminare di analisi esplorativa dei dati, seguita da pre-processing con selezione della *slice* più significativa, normalizzazione delle intensità, filtraggio mediano del rumore e costruzione di rappresentazioni multimodali mediante fusione pesata delle sequenze *FLAIR*, *T1c* e *T2*. La segmentazione è realizzata attraverso una strategia a cascata che combina sogliatura multilivello con *Otsu*, *Region Growing* con seme automatico e *Marker-Controlled Watershed*, mentre il post-processing morfologico consente di rifinire le maschere ottenute.

Le prestazioni sono state valutate con le metriche *Dice Score*, *Sensitivity* e *Precision* per singolo paziente e in forma aggregata sull'intero dataset. I risultati mostrano che la configurazione multimodale *Fusion3* risulta la più efficace, con valori medi pari a *Dice Score* $= 0.806$, *Sensitivity* $= 0.744$ e *Precision* $= 0.935$, superando sia la migliore configurazione monomodale, *FLAIR*, sia la configurazione bimodale *Fusion2*. Le sequenze *T2* e *T1c*, considerate singolarmente, mostrano prestazioni inferiori, in quanto meno rappresentative della lesione.

Nel complesso, i risultati confermano che l'integrazione di informazioni complementari provenienti da più sequenze MRI può migliorare l'accuratezza della segmentazione rispetto all'uso di singole modalità. Inoltre, anche gli approcci tradizionali, seppur meno complessi rispetto ai metodi basati su *Deep Learning*, possono fornire risultati significativi nel contesto analizzato.

Indice

1 Introduzione **1**
1.1 Contesto e Motivazioni 1
1.2 Obiettivi del Progetto 1
1.3 Struttura del Documento 2

2 Dataset e Sequenze MRI **3**
2.1 Dataset BraTS (Medical Segmentation Decathlon) 3
2.2 Sequenze MRI 4
2.2.1 T1-pesata (T1) 4
2.2.2 T1 con mezzo di contrasto (T1c) 4
2.2.3 T2-pesata (T2) 5
2.2.4 FLAIR 5
2.3 Fusione Multimodale 5

3 Metodologia e Sviluppo **6**
3.1 Architettura della Pipeline di Elaborazione 6
3.2 Implementazione in MATLAB 7
3.2.1 Script Principale (Main) 7
3.2.2 Analisi Esplorativa dei Dati (EDA) 8
3.2.3 Pre-Processing 11
3.2.4 Segmentazione 16
3.2.5 Post-Processing 22
3.2.6 Valutazione 25

4 Risultati **27**
4.1 Analisi delle Metriche 27
4.2 Analisi dei Casi Rappresentativi 27
4.2.1 Casi Migliori 28
4.2.2 Casi Peggiori 30

5 Conclusioni **32**
5.1 Limiti Strutturali 32
5.2 Sviluppi Futuri 32
5.2.1 K-Means 33
5.2.2 Metodi Edge-Based 33

Bibliografia **34**

Capitolo 1

Introduzione

1.1 Contesto e Motivazioni

I gliomi rappresentano la tipologia più frequente di tumore cerebrale negli adulti. La pianificazione di interventi chirurgici e di terapie richiede una conoscenza precisa delle caratteristiche della lesione. In tale contesto, la segmentazione delle immagini mediche consente di delineare i contorni tumorali rispetto al tessuto sano circostante [1].

Questa operazione viene eseguita manualmente da medici esperti. Tuttavia, la segmentazione manuale presenta alcune criticità, in quanto è un processo lento e soggetto all'interpretazione umana. I bordi dei gliomi, infatti, risultano spesso sfumati a causa del basso contrasto delle immagini radiologiche, causando ambiguità nella segmentazione di una stessa lesione da parte di diversi medici. Tale mancanza di riproducibilità rende necessario lo sviluppo di algoritmi capaci di automatizzare l'estrazione della regione tumorale [2].

1.2 Obiettivi del Progetto

L'obiettivo principale del progetto consiste nell'implementazione di una pipeline per la segmentazione di tumori cerebrali basata su tecniche tradizionali di *Image Processing*, quali *Otsu* multilivello, *Region Growing* con seme automatico e *Marker-Controlled Watershed*, organizzate secondo un flusso di elaborazione a cascata.

La segmentazione consiste nella rilevazione di strutture di interesse all'interno delle immagini mediche e la letteratura recente privilegia modelli di *Deep Learning* che operano come *black-box*, rendendo meno immediata l'interpretazione delle scelte di segmentazione.

Pertanto, questo lavoro propone un approccio sperimentale, il cui focus risiede nella validazione della fusione multimodale delle immagini rispetto all'utilizzo delle singole sequenze MRI (*Magnetic Resonance Imaging*) in un contesto di segmentazione binaria bidimensionale. Attraverso l'analisi comparativa, si intende verificare l'ipotesi secondo cui la combinazione delle informazioni provenienti da diverse sequenze in input (*FLAIR*, *T1c* e *T2*) consenta un miglioramento complessivo nell'identificazione del tumore.

A seguito di una fase preliminare di esplorazione dei dati e di pre-processing, dai volumi tridimensionali vengono estratte le *slice* bidimensionali più significative.

Successivamente, tali immagini vengono elaborate confrontando sia le singole sequenze che le configurazioni di fusione bimodale e multimodale. Le maschere di segmentazione ottenute sono, quindi, sottoposte a una fase di post-processing morfologico, finalizzata al raffinamento dei risultati.

Infine, vengono calcolate le metriche quantitative di segmentazione e generati i corrispondenti output grafici.

1.3 Struttura del Documento

Il documento è articolato nei seguenti capitoli, ciascuno dedicato a una specifica fase del lavoro:

- Il **Capitolo 2** introduce il dataset utilizzato per l'analisi e vengono descritte le caratteristiche delle diverse sequenze di risonanza magnetica. Inoltre, viene illustrata la struttura dei volumi tridimensionali in formato NIfTI, la loro rappresentazione in *slice* bidimensionali e le modalità di gestione dei diversi pazienti presenti.

- Il **Capitolo 3** descrive nel dettaglio la pipeline e presenta l'architettura modulare sviluppata in MATLAB, dal pre-processing e fusione delle sequenze, all'estrazione dei marker iniziali tramite sogliatura di *Otsu* multilivello per il *Region Growing*, fino all'output finale ottenuto mediante *Marker-Controlled Watershed*.

- Il **Capitolo 4** definisce le metriche di valutazione utilizzate e discute i risultati ottenuti mediante tabelle e grafici comparativi, con un'analisi approfondita sia dei casi caratterizzati da prestazioni elevate sia di quelli con risultati insoddisfacenti, indagandone le possibili cause.

- Il **Capitolo 5**, infine, riassume i risultati ottenuti e propone possibili sviluppi futuri.

Capitolo 2

Dataset e Sequenze MRI

In questo capitolo viene presentato il dataset utilizzato nel progetto, in riferimento alle caratteristiche delle sequenze di risonanza magnetica impiegate. La comprensione delle loro proprietà è, infatti, fondamentale per interpretare le informazioni contenute nelle immagini e per implementare correttamente gli algoritmi di segmentazione.

2.1 Dataset BraTS (Medical Segmentation Decathlon)

Per l'analisi è stato utilizzato il dataset BraTS (*Brain Tumor Segmentation Benchmark 2016/2017*), che rappresenta uno standard di riferimento nella comunità scientifica per la valutazione di algoritmi di segmentazione automatica in ambito medicale [2]. Nello specifico, contiene volumi MRI multimodali annotati da medici esperti.

Il dataset è disponibile pubblicamente sulla piattaforma *Medical Segmentation Decathlon* (MSD)[1], una competizione progettata per valutare le prestazioni di diversi algoritmi di *Image Processing* su molteplici task [1].

Per il lavoro proposto, è stata impiegata la task *Task01_BrainTumor*, relativa alla segmentazione di gliomi cerebrali.

Dal punto di vista strutturale, il dataset è organizzato in tre sottoinsiemi principali:

- **imagesTr**: contiene i volumi MRI dei pazienti utilizzati per il training;
- **labelsTr**: contiene le corrispondenti *ground truth* annotate manualmente dai medici;
- **imagesTs**: contiene i volumi di test, senza annotazioni.

Nel presente lavoro sono stati utilizzati esclusivamente i dati annotati (*imagesTr* e *labelsTr*), così da valutare le prestazioni della pipeline mediante confronto diretto con la *ground truth*. Il sottoinsieme di test non è stato considerato, poiché tipicamente destinato alla validazione di approcci di *Machine Learning*.

[1] `http://medicaldecathlon.com/`

Il dataset di training comprende 484 pazienti, ciascuno identificato da un file in formato *.nii.gz* contenente un volume multimodale. Ogni volume è rappresentato come un tensore quadridimensionale, in cui le prime tre dimensioni corrispondono allo spazio tridimensionale dell'immagine, mentre la quarta dimensione rappresenta le diverse sequenze MRI acquisite.

Nella versione MSD, i volumi sono stati ricampionati al fine di ottenere una risoluzione spaziale con *voxel* (pixel volumetrici) di $1 \times 1 \times 1$ mm ed è stato effettuato lo *skull-stripping*, ovvero la rimozione del cranio dall'acquisizione. Inoltre, le diverse modalità MRI sono state normalizzate in intensità e posizionate nello stesso sistema di riferimento spaziale. A seguito di tali operazioni, tutti i volumi presentano dimensioni uniformi di $240 \times 240 \times 155$ voxel e un numero di *slice* pari a 155 per tutti i pazienti.

Le annotazioni di riferimento sono fornite come maschere segmentate, in cui i voxel sono etichettati secondo diverse classi patologiche, tra cui *edema peritumorale*, *core tumorale non-enhancing* (necrotico) e *tumore enhancing* (attivo), oltre allo sfondo. Nella pipeline, tali etichette sono state binarizzate per ottenere una segmentazione di tipo tumore/non-tumore, per semplificarne l'implementazione.

2.2 Sequenze MRI

Ogni modalità di risonanza magnetica presenta specifiche proprietà di contrasto, che evidenziano differenti caratteristiche dei tessuti e della struttura della lesione [2].

- **FLAIR** (*Fluid Attenuated Inversion Recovery*);
- **T1** (T1 pesata);
- **T1c** (T1 con mezzo di contrasto);
- **T2** (T2 pesata).

2.2.1 T1-pesata (T1)

Le immagini *T1* pesate sono caratterizzate da un buon contrasto tra sostanza grigia, sostanza bianca e liquido cerebrospinale. In questa modalità, i tessuti appaiono con intensità differenti, consentendo una visualizzazione chiara della struttura anatomica globale.

Risulta utile per la localizzazione generale delle strutture cerebrali, ma è poco sensibile nella rilevazione delle regioni tumorali, in quanto molte lesioni presentano intensità simili ai tessuti circostanti. Infatti, in assenza di mezzo di contrasto, le aree tumorali risultano difficilmente distinguibili.

2.2.2 T1 con mezzo di contrasto (T1c)

Nella sequenza *T1c*, la somministrazione di un agente di contrasto a base di gadolinio evidenzia le aree tumorali attive, caratterizzate da una permeabilità vascolare aumentata.

Questa proprietà permette al mezzo di contrasto di accumularsi nei tessuti, rendendo tali regioni iperintense rispetto a quelle sane circostanti. Difatti, questa sequenza è efficace nell'identificazione della porzione attiva della lesione, ma non fornisce informazioni sull'estensione totale del tumore.

2.2.3 T2-pesata (T2)

Le immagini *T2* pesate sono sensibili al contenuto di acqua nei tessuti. Di conseguenza, le regioni contenenti liquidi, come il liquido cerebrospinale o gli edemi, appaiono iperintense.

Tale sequenza contribuisce all'individuazione dell'estensione della lesione, ma è meno specifica rispetto alla sequenza *T1* con mezzo di contrasto, in quanto non consente di distinguere in modo accurato le diverse componenti tumorali. Per questo motivo, le immagini *T2* risultano utili se integrate con altre modalità complementari.

2.2.4 FLAIR

La sequenza *FLAIR* sopprime il segnale del liquido cerebrospinale, mantenendo alta la visibilità delle anomalie nei tessuti cerebrali.

Essa è utile per localizzare l'edema peritumorale, che appare come una regione iperintensa estesa attorno alla lesione. A differenza della sequenza *T1* con mezzo di contrasto, che evidenzia la componente tumorale attiva, la *FLAIR* consente di osservare l'estensione complessiva del tumore, includendo anche le aree non attive.

2.3 Fusione Multimodale

Come descritto, l'integrazione di più modalità MRI permette di migliorare le prestazioni degli algoritmi di segmentazione. Tuttavia, ciascuna sequenza presenta vantaggi e limitazioni specifiche.

Pertanto, nella pipeline è stata adottata una strategia di combinazione pesata delle sequenze per ogni paziente. In particolare, è stata implementata una tecnica di fusione a livello di intensità dei pixel prima della fase di segmentazione, come presentato in alcuni lavori di ricerca [3].

Tale approccio fornisce in ingresso alla pipeline un'immagine arricchita, che valorizza le informazioni più rilevanti e riduce le ambiguità legate alle singole modalità.

Capitolo 3

Metodologia e Sviluppo

Nel capitolo viene presentata l'architettura generale del sistema. Successivamente, l'implementazione dei diversi moduli della pipeline in MATLAB viene analizzata in dettaglio, con il supporto rappresentativo del paziente *BRATS_218.nii.gz*.

3.1 Architettura della Pipeline di Elaborazione

La pipeline è strutturata in fasi sequenziali, come illustrato in Figura 3.1.

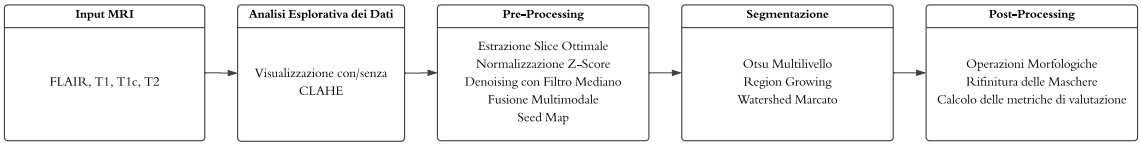

Figura 3.1: Schema a blocchi della pipeline di segmentazione proposta.

La pipeline prevede una fase preliminare e facoltativa di analisi esplorativa (*Exploratory Data Analysis*, EDA), finalizzata al confronto delle diverse sequenze MRI mediante visualizzazione delle immagini, miglioramento del contrasto, rendering tridimensionale del volume e analisi degli istogrammi di intensità.

In seguito, le immagini sono sottoposte a una fase di pre-processing che include l'estrazione della *slice* più rilevante, la normalizzazione delle intensità, la riduzione del rumore con filtro mediano e la costruzione di rappresentazioni multimodali. Viene, inoltre, generata la *seed map*, utile per individuare la regione iniziale da cui avviare la segmentazione.

Quest'ultima è implementata mediante una strategia a cascata che combina più tecniche [4]. Inizialmente, viene applicata una sogliatura multilivello basata sul metodo di *Otsu* per individuare le regioni di interesse. Successivamente, l'algoritmo *Region Growing* espande tali regioni a partire dal seme e, infine, il *Marker-Controlled Watershed* viene impiegato per migliorare la maschera di segmentazione ottenuta.

Al termine del processo, tali maschere vengono rifinite attraverso una fase di post-processing basata su operazioni morfologiche per riempire eventuali lacune e rimuovere componenti connesse non necessarie.

Infine, le prestazioni della pipeline sono valutate mediante un confronto tra le maschere predette e le corrispondenti *ground truth* binarie, utilizzando metriche standard quali *Dice Score*, *Precision* e *Sensitivity*.

3.2 Implementazione in MATLAB

Per l'implementazione in ambiente MATLAB, sono state utilizzate le funzionalità offerte dall'*Image Processing Toolbox* [5]. Inoltre, il progetto è stato organizzato secondo una struttura modulare in funzioni, per separare le fasi di elaborazione.

All'interno della cartella principale del progetto sono presenti le sottocartelle relative alla gestione dei dati e dei risultati. La cartella */dataset* contiene i volumi MRI in formato NIfTI per tutti i pazienti considerati e le corrispondenti *ground truth*. La cartella */results* è, invece, destinata al salvataggio dei risultati. Per ciascun paziente, la pipeline salva le figure relative alle sequenze originali, agli step di pre-processing, ai risultati intermedi della segmentazione, al post-processing e al confronto finale con la *ground truth*.

3.2.1 Script Principale (Main)

Il file *main.m* costituisce il punto di ingresso dell'intera pipeline e gestisce il caricamento dei dati, il richiamo sequenziale dei moduli di pre-processing, segmentazione, valutazione e la generazione dei risultati grafici e numerici.

Caricamento dei file Lo script definisce i percorsi delle cartelle contenenti i volumi MRI e le relative *ground truth*.

Mediante la funzione *dir* vengono individuati tutti i file con estensione *.nii.gz* presenti nella cartella delle immagini, ottenendo l'elenco completo dei pazienti da elaborare. Il numero totale dei file viene memorizzato nella variabile *num_files*.

Prima di avviare l'elaborazione, viene inizializzato un array di struct denominato *metrics*, di dimensione pari al numero di pazienti. Ogni elemento della struttura contiene il nome del paziente e le metriche di valutazione associate alle cinque configurazioni sperimentali (*FLAIR*, *T1c*, *T2*, *Fusion2* e *Fusion3*).

Elaborazione iterativa Mediante un ciclo *for* che itera su tutti i pazienti del dataset, vengono definiti il nome del file corrente, i percorsi specifici dell'immagine e della *ground truth* e la cartella di output dedicata al paziente.

Per ciascun paziente, lo script richiama in sequenza la funzione *pre_processing*, che restituisce le immagini preprocessate delle diverse sequenze, le fusioni multimodali, la maschera di *ground truth* della *slice* selezionata e la *seed map* per l'avvio della segmentazione. Inoltre, con chiamate ripetute alla funzione *segmentation*, si ottengono le maschere di segmentazione post-processate per ciascuna delle configurazioni. Successivamente, attraverso la funzione *evaluation*, ciascuna maschera predetta viene confrontata con la *ground truth* e vengono calcolate le metriche di valutazione, poi salvate nella struttura *metrics* aggiornando i campi relativi al paziente corrente.

Generazione dei risultati Per ciascun paziente viene costruita una figura (*comparison_results.png*) composta da sei subplot disposti su una griglia 2×3. Nel primo pannello viene visualizzata la *ground truth* con immagine *T1* di sfondo, mentre nei cinque pannelli successivi vengono mostrate le segmentazioni ottenute dalle

diverse configurazioni con il contorno della *ground truth* in verde e quello della segmentazione in rosso.

Durante l'esecuzione, lo script stampa nella Command Window una riga di avanzamento per ogni paziente, riportando il numero progressivo del caso e i valori di *Dice Score* ottenuti per tutte le configurazioni considerate.

Al termine dell'elaborazione, viene stampato il riepilogo delle metriche medie e vengono prodotti due file *CSV*. Il primo, *detailed.csv*, contiene una riga per ciascun paziente e riporta tutte le metriche ottenute per ogni configurazione. Il secondo, *global.csv*, contiene invece i valori medi delle metriche calcolate sull'intero dataset per ciascuna sequenza.

3.2.2 Analisi Esplorativa dei Dati (EDA)

La fase di EDA consente di confrontare il comportamento delle diverse sequenze MRI, analizzandone sia l'aspetto visivo sia la distribuzione delle intensità prima e dopo il miglioramento del contrasto.

Caricamento dei dati Inizialmente, viene selezionato il paziente desiderato e vengono definiti i percorsi del volume MRI e della *ground truth* in formato NIfTI. Inoltre, viene creata la cartella per il salvataggio delle figure prodotte durante l'analisi. Successivamente, vengono letti i volumi con la funzione *niftiread* e convertiti in formato *double*.

L'analisi è effettuata in modo semplificato sulla *slice* centrale del volume, la numero 78. Nella pipeline finale, invece, la selezione della *slice* avviene in modo automatico, individuando quella con maggiore estensione della regione tumorale.

Visualizzazione delle sequenze originali A partire dalla sequenza *FLAIR*, viene costruita una maschera cerebrale binaria per limitare l'analisi ai soli pixel appartenenti al cervello, escludendo lo sfondo nero che altererebbe la distribuzione delle intensità.

Lo script genera una figura contenente, nella riga superiore, la visualizzazione delle quattro sequenze originali e, nella riga inferiore, i corrispondenti istogrammi delle intensità all'interno della regione cerebrale. Per la visualizzazione delle immagini viene utilizzata la funzione *mat2gray*, che rimappa i valori nell'intervallo $[0, 1]$, come illustrato in Figura 3.2.

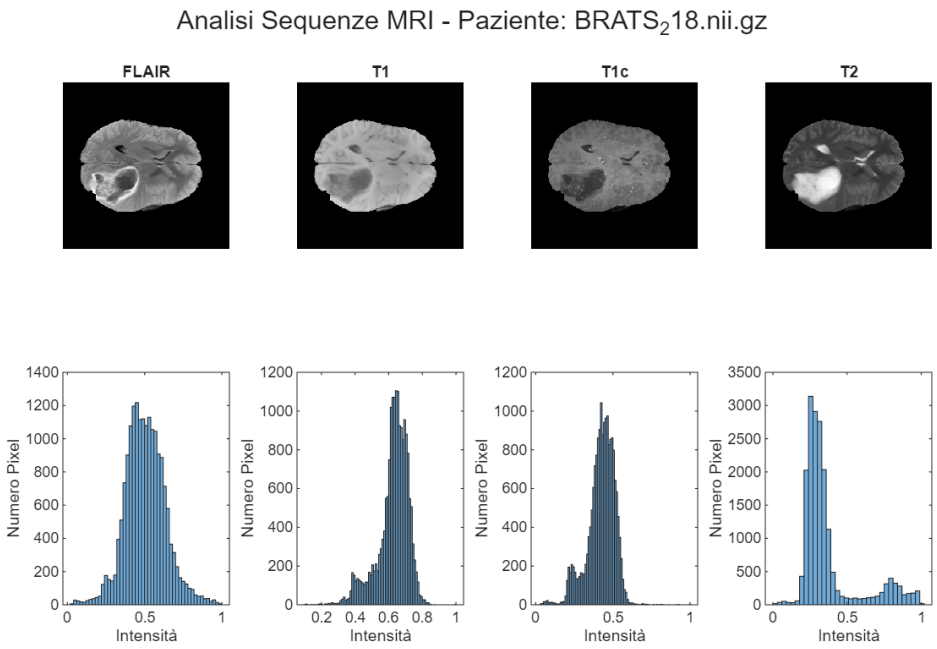

Figura 3.2: Analisi delle sequenze MRI originali per le immagini *FLAIR*, *T1*, *T1c* e *T2* estratte dalla *slice* selezionata e i relativi istogrammi delle intensità nella regione cerebrale.

Miglioramento del contrasto con CLAHE Per migliorare la visualizzazione, per ciascuna sequenza è stata applicata la tecnica di *Contrast Limited Adaptive Histogram Equalization* (CLAHE), implementata tramite la funzione *adapthisteq*. Nel codice è stato impostato il parametro *ClipLimit = 0.015*, che controlla la soglia massima dei livelli di intensità per ciascun blocco dell'immagine, limitando i picchi più elevati e redistribuendo uniformemente l'eccesso sugli altri livelli. La Figura 3.3 mostra le immagini dopo l'enhancement e gli istogrammi corrispondenti.

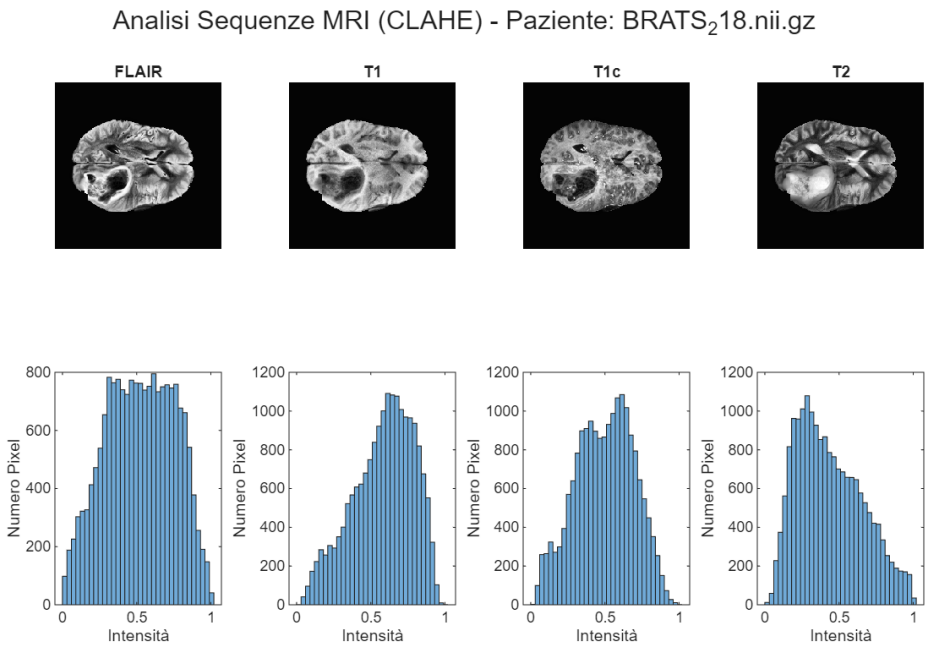

Figura 3.3: Analisi delle sequenze MRI dopo miglioramento del contrasto mediante CLAHE per le immagini e le rispettive distribuzioni di intensità.

Visualizzazione volume 3D Infine, lo script utilizza la funzione *volshow* per visualizzare interattivamente il volume tridimensionale della sequenza *FLAIR*, come mostrato in Figura 3.4.

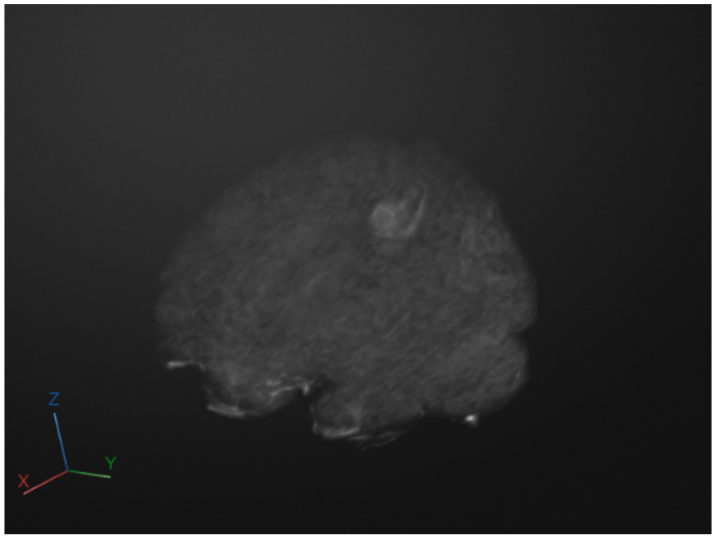

Figura 3.4: Rendering tridimensionale interattivo della sequenza *FLAIR* per l'analisi qualitativa della struttura cerebrale.

3.2.3 Pre-Processing

La fase di pre-processing ha il compito di trasformare i dati grezzi estratti dal dataset in immagini adeguate per la segmentazione.

Selezione automatica della slice più rilevante All'inizio, vengono caricati il volume MRI e la relativa *ground truth* tramite la funzione *niftiread*, poi convertiti in formato *double*. A differenza di quanto descritto per la fase di EDA, viene individuata automaticamente la *slice* più significativa calcolando, per ognuna di esse, il numero di pixel appartenenti alla regione tumorale nella *ground truth* e selezionando quella che presenta la massima estensione della lesione.

Detta $G(x, y, z)$ la *ground truth* binaria tridimensionale, lo score associato alla *slice* z è definito come:

$$s(z) = \sum_x \sum_y \mathbf{1}\big(G(x, y, z) > 0\big)$$

La *slice* scelta corrisponde quindi a:

$$z_{\text{best}} = \arg\max_z s(z)$$

Identificata tale *slice*, da essa vengono estratte le sequenze *FLAIR*, *T1*, *T1c*, *T2* e le maschere di *ground truth* corrispondenti.

Costruzione della maschera cerebrale La maschera cerebrale della regione di interesse (ROI) viene costruita a partire dalla sequenza *FLAIR*, selezionando i pixel con intensità positiva e applicando l'operazione *imfill* per riempire eventuali lacune interne.

Analisi delle sequenze grezze Il codice genera una figura contenente le sequenze grezze e i relativi istogrammi delle intensità nella regione cerebrale per la sola *slice* ottimale individuata, come riportato in Figura 3.5.

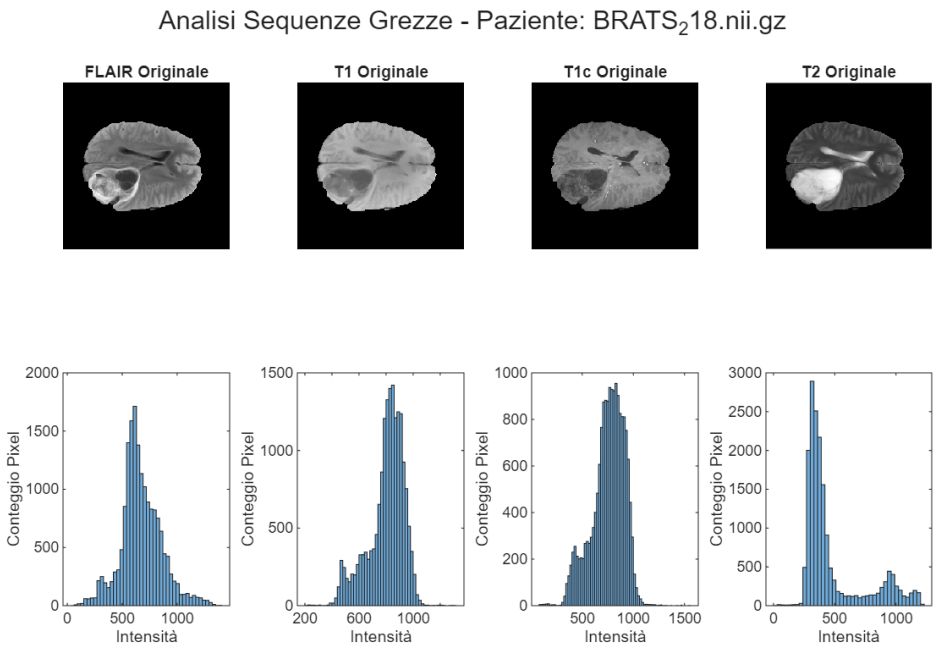

Figura 3.5: Sequenze MRI grezze estratte dalla *slice* ottimale, con i relativi istogrammi delle intensità calcolati nella ROI cerebrale.

Normalizzazione delle intensità La normalizzazione viene applicata ai pixel interni alla maschera mediante trasformazione Z-score. Per una generica immagine I, la normalizzazione è definita come:

$$I_{\text{norm}}(x, y) = \frac{I(x, y) - \mu_I}{\sigma_I}$$

dove μ_I e σ_I rappresentano, rispettivamente, la media e la deviazione standard delle intensità.

Nel codice, questa operazione viene applicata a tutte le sequenze. Tuttavia, soltanto le sequenze *FLAIR*, *T1c* e *T2* vengono poi impiegate nella costruzione delle fusioni multimodali, mentre la *T1* viene mantenuta come riferimento visivo. Dopo la normalizzazione, i pixel esterni alla maschera cerebrale vengono azzerati per sopprimere lo sfondo e le sequenze vengono traslate nell'intervallo $[0, 1]$ con la funzione *mat2gray*.

Riduzione del rumore Per attenuare il rumore preservando i contorni delle strutture anatomiche, viene applicato un filtro mediano bidimensionale con kernel 3×3, implementato tramite la funzione *medfilt2*. Il filtro mediano è un operatore non lineare adatto alla rimozione di rumore impulsivo, che sostituisce il valore di ciascun pixel con la mediana dei valori presenti nel suo intorno locale.

Le Figure 3.6, 3.7 e 3.8 mostrano i principali step del pre-processing (sequenza grezza, normalizzata e filtrata), insieme agli istogrammi delle intensità.

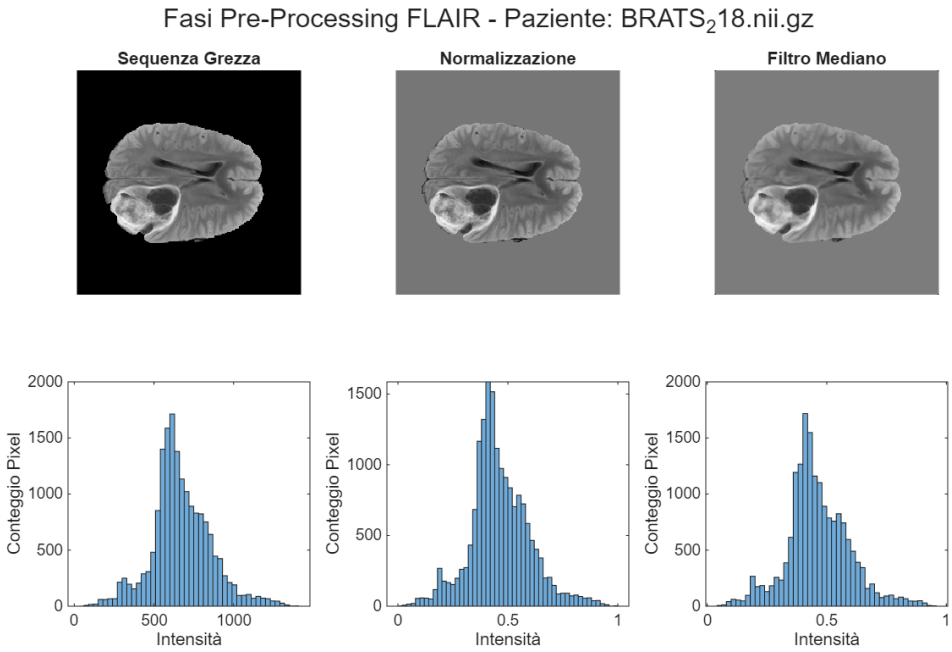

Figura 3.6: Fasi di pre-processing della sequenza *FLAIR*: immagine grezza, normalizzazione delle intensità e filtraggio mediano, con i rispettivi istogrammi.

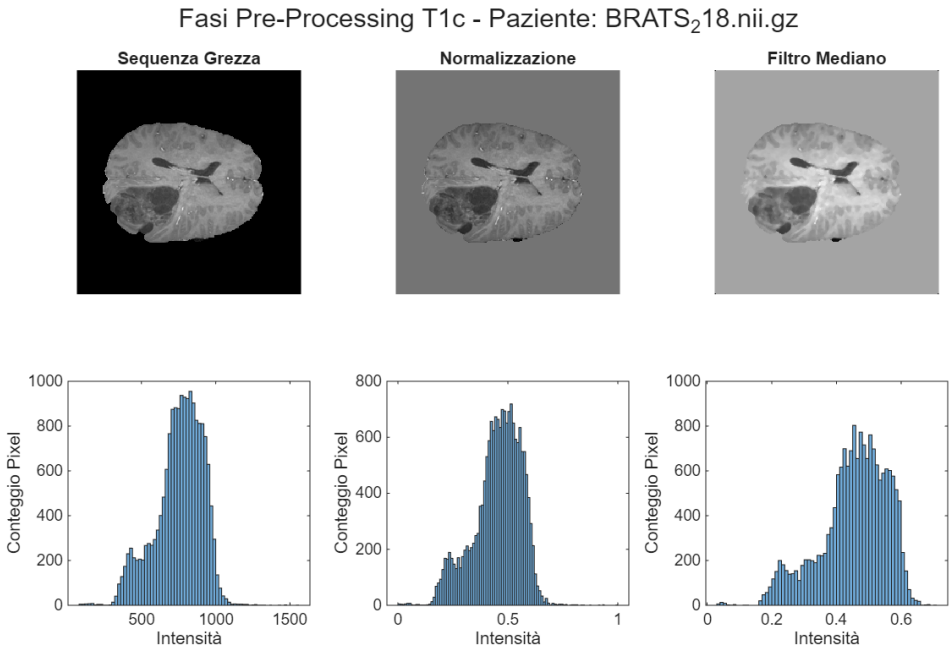

Figura 3.7: Fasi di pre-processing della sequenza *T1c*: immagine grezza, normalizzazione delle intensità e filtraggio mediano, con i rispettivi istogrammi.

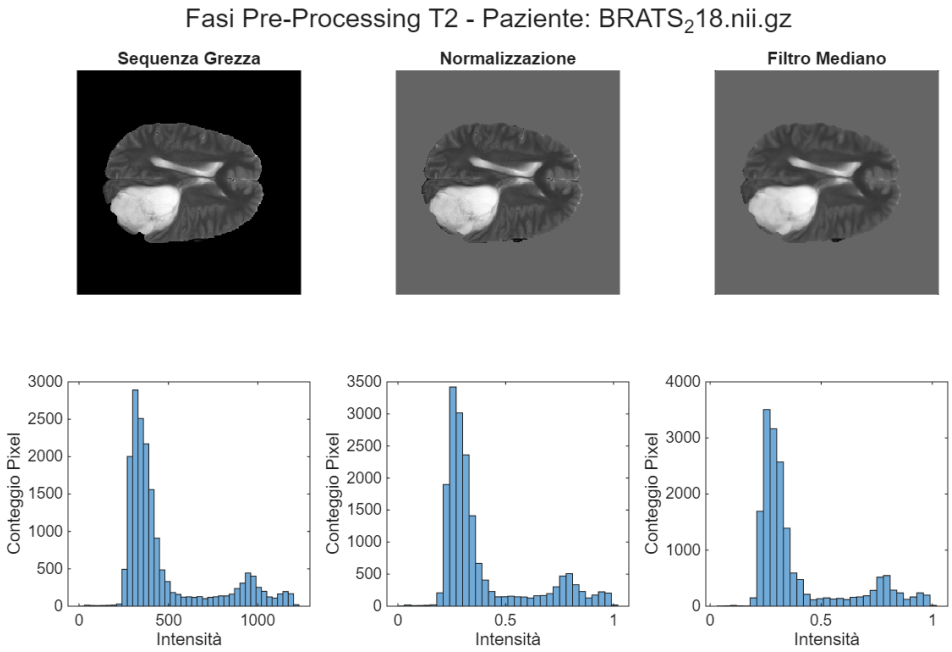

Figura 3.8: Fasi di pre-processing della sequenza *T2*: immagine grezza, normalizzazione delle intensità e filtraggio mediano, con i rispettivi istogrammi.

Costruzione delle rappresentazioni multimodali Nel codice vengono costruite due configurazioni di fusione secondo una combinazione lineare pesata:

$$I_{\text{Fusion2}} = 0.6\, I_{\text{FLAIR}} + 0.4\, I_{\text{T1c}}$$

$$I_{\text{Fusion3}} = 0.5\, I_{\text{FLAIR}} + 0.2\, I_{\text{T1c}} + 0.3\, I_{\text{T2}}$$

La prima configurazione, denominata *Fusion2*, integra l'informazione proveniente da *FLAIR* e *T1c*, mentre la seconda, *Fusion3*, include anche il contributo della sequenza *T2*. I pesi sono stati scelti empiricamente, attribuendo maggiore importanza alla modalità *FLAIR*, poiché rappresentativa dell'estensione complessiva della lesione, ma mantenendo un contributo complementare per *T1c* e *T2*.

Le Figure 3.9 e 3.10 mostrano il risultato di tali combinazioni e i corrispondenti istogrammi delle intensità.

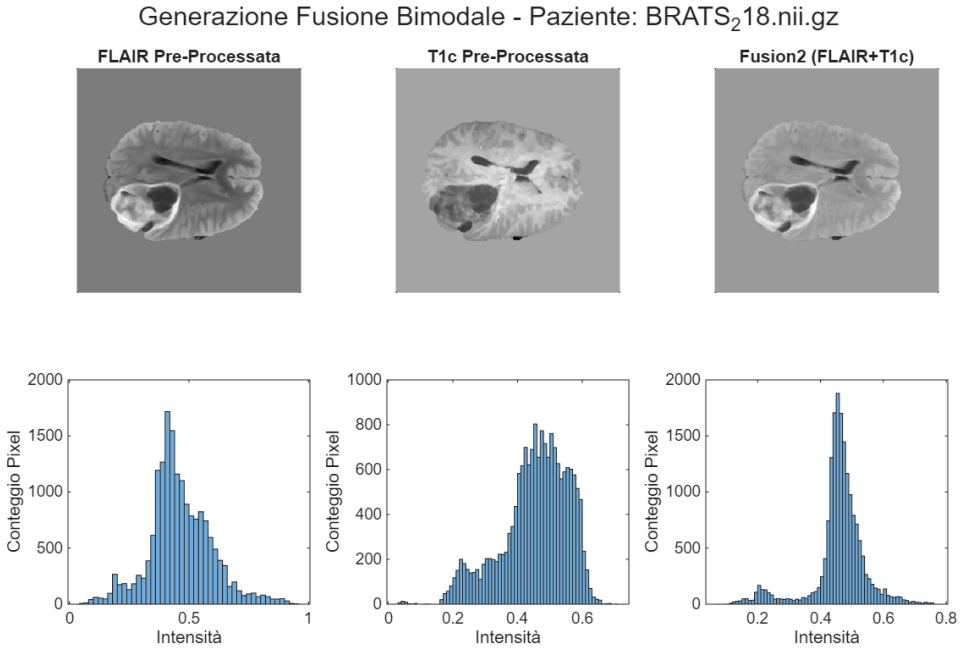

Figura 3.9: Generazione della fusione bimodale a partire dalle sequenze *FLAIR* e *T1c* pre-processate, con i corrispondenti istogrammi delle intensità.

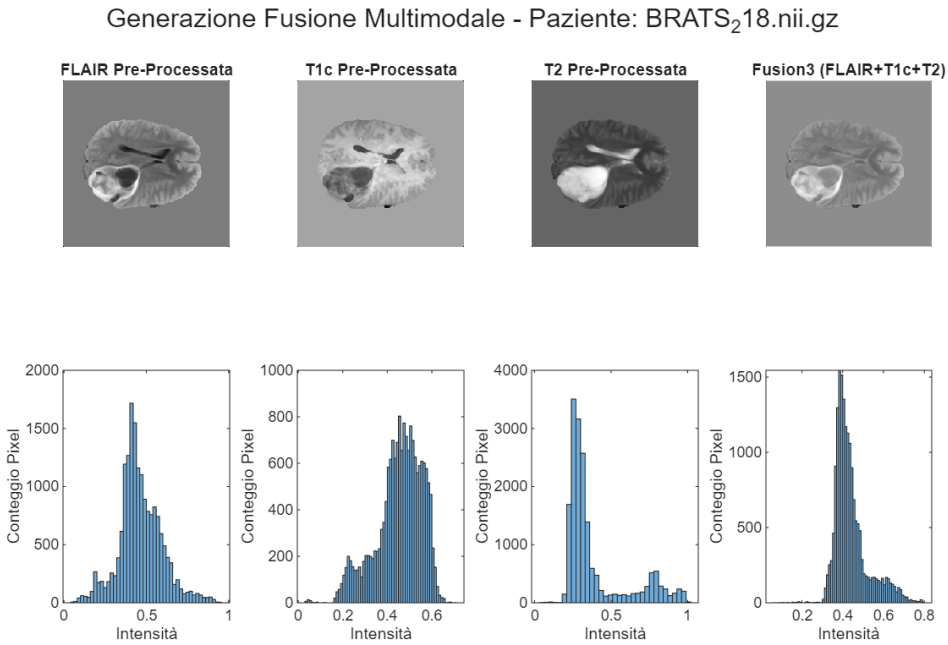

Figura 3.10: Generazione della fusione multimodale a partire dalle sequenze *FLAIR*, *T1c* e *T2* pre-processate, con i corrispondenti istogrammi delle intensità.

Generazione della seed map La *seed map* in Figura 3.12 è stata ottenuta applicando un filtro gaussiano alla rappresentazione *Fusion3* tramite la funzione *imgaussfilt* con parametro $\sigma = 3$. A differenza del filtro mediano, impiegato per la riduzione del rumore locale, introduce una sfocatura controllata per smussare le va-

riazioni locali e far emergere la regione a intensità globale più elevata. Il valore di σ non è stato fissato manualmente, ma scelto sperimentalmente valutando l'andamento del *Dice Score* medio al variare del livello di sfocatura gaussiana, come mostrato in Figura 3.11.

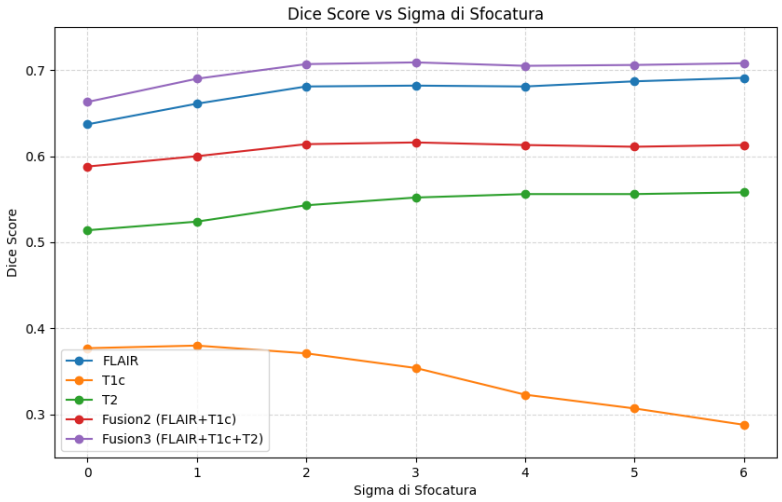

Figura 3.11: Andamento del *Dice Score* medio al variare del parametro di sfocatura gaussiana σ utilizzato per la generazione della *seed map*.

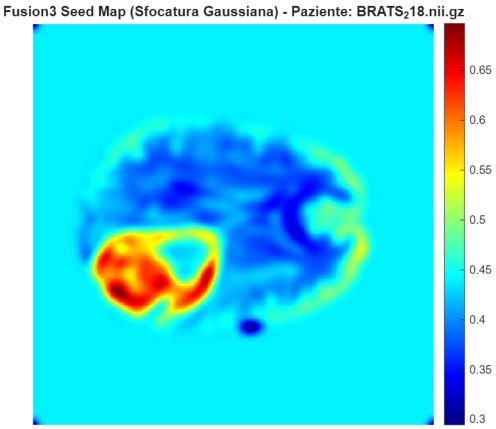

Figura 3.12: *Seed map* ottenuta applicando una sfocatura gaussiana alla rappresentazione *Fusion3*.

3.2.4 Segmentazione

La fase principale di segmentazione è implementata nel modulo *segmentation.m*. L'obiettivo è ottenere una maschera binaria che identifichi la regione tumorale nelle immagini pre-processate mediante una strategia a cascata, che combina le tre tecniche classiche di *Image Processing* presentate in precedenza.

Selezione automatica del seme Prima di avviare la segmentazione, si individua automaticamente il seme iniziale sfruttando la *seed map* generata nella fase di preprocessing. In particolare, viene identificato il pixel corrispondente al massimo della mappa:

$$(x_{\text{seed}}, y_{\text{seed}}) = \arg\max_{(x,y)} SeedMap(x, y)$$

Otsu multilivello Il primo passo della segmentazione consiste nella sogliatura multilivello basata sul metodo di *Otsu* [6]. Tale approccio determina una o più soglie di intensità massimizzando la varianza inter-classe e minimizzando la varianza intra-classe tra i livelli di grigio. Il metodo opera direttamente sull'istogramma dei livelli di grigio dell'immagine, ricercando la soglia che suddivide i pixel in classi omogenee al loro interno ma il più possibile separate tra loro.

Nel lavoro viene utilizzata una sogliatura a due livelli, ottenuta tramite la funzione *multithresh*, che suddivide l'immagine in tre classi di intensità. La maschera iniziale viene poi costruita selezionando i pixel appartenenti alla classe a intensità più elevata:

$$M_{\text{Otsu}}(x, y) = \begin{cases} 1 & \text{se } I(x, y) > T_2 \\ 0 & \text{altrimenti} \end{cases}$$

dove T_2 rappresenta la soglia più alta restituita da *Otsu*.

Region Growing con seme automatico A partire dal seme selezionato, viene applicato un algoritmo di *Region Growing* mediante la funzione *region_growing.m*. Tale tecnica segmenta l'immagine espandendo iterativamente una regione iniziale verso i pixel adiacenti che soddisfano un opportuno criterio di omogeneità [7].

Un punto viene aggiunto alla regione se la sua intensità supera una determinata soglia calcolata a partire dalla maschera di *Otsu*. Tale soglia viene scelta come il 6° percentile delle intensità dei pixel appartenenti a M_{Otsu}:

$$T_{\text{RG}} = \text{percentile}_6 \left(I(x, y) \mid M_{\text{Otsu}}(x, y) = 1 \right)$$

Dunque, si considerano tutte le intensità dei pixel nella maschera, si ordinano in senso crescente e si seleziona il valore al di sotto del quale cade il 6% dei campioni. L'utilizzo di un percentile rende il metodo dinamico rispetto alla distribuzione delle intensità del singolo paziente. Il valore corrispondente è individuato empiricamente, confrontando i risultati di *Dice Score* al variare del percentile, come illustrato in Figura 3.13.

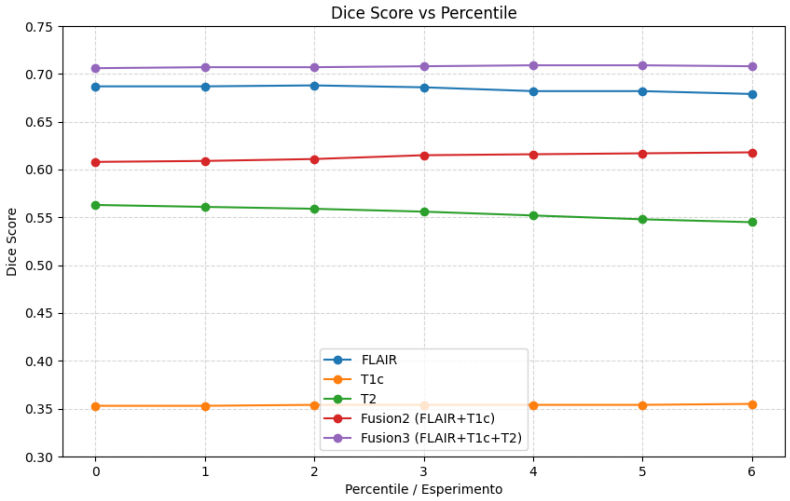

Figura 3.13: Andamento del *Dice Score* medio al variare del percentile utilizzato per definire la soglia del *Region Growing*.

L'espansione viene effettuata considerando un intorno a 8-connettività, che include non solo i quattro vicini ortogonali, ma anche i quattro vicini diagonali, garantendo una crescita continua della regione tumorale e riducendo la frammentazione.

Dal punto di vista implementativo, la funzione *region_growing.m* riceve in ingresso l'immagine I, le coordinate del seme iniziale ($seedY$, $seedX$) e la soglia di intensità T_{RG} e costruisce progressivamente una maschera binaria (*mask*), inizialmente vuota, e una mappa (*visited*) che tiene traccia dei pixel già esaminati.

Per gestire l'esplorazione è utilizzata una coda, realizzata con due vettori *Q_row* e *Q_col*, che memorizzano le coordinate di riga e colonna dei pixel da visitare. Il seed iniziale viene inserito in coda, marcato come visitato e incluso nella maschera finale.

Successivamente, l'algoritmo esegue le iterazioni finché la coda non risulta vuota. A ogni iterazione viene estratto il pixel corrente dalla testa della coda e vengono analizzati gli 8 vicini. Per ciascun vicino, si verifica che gli indici non eccedano i limiti dell'immagine e si controlla se il pixel è già stato visitato.

In caso negativo, esso viene segnato come visitato e, se la sua intensità risulta superiore alla soglia *thresh*, il pixel viene aggiunto alla regione segmentata e accodato. Diversamente, il pixel viene escluso dalla regione.

Watershed con marcatori La maschera prodotta dal *Region Growing* viene migliorata mediante l'algoritmo *Marker-Controlled Watershed* [8], che considera l'immagine come una superficie topografica e separa le regioni in base alle zone che si sviluppano attorno agli stessi minimi locali.

Tuttavia, può soffrire di *over-segmentation*, generando un numero elevato di regioni piccole e sparse. Per ridurre questo effetto, sono stati impiegati marcatori espliciti estratti dal *Region Growing* [9]. In particolare, viene calcolata la trasformata della distanza inversa sulla maschera ottenuta da esso:

$$D = -\ \mathrm{bwdist}(\neg M_{\mathrm{RG}})$$

dove bwdist rappresenta la distanza euclidea e $\neg M_{\mathrm{RG}}$ indica i pixel esterni alla maschera. Successivamente, i minimi locali della superficie vengono imposti utilizzando la maschera di *Otsu* come marker:

$$D_{\mathrm{mod}} = \mathrm{imimposemin}(D, M_{\mathrm{Otsu}})$$

Per evitare l'espansione verso lo sfondo, la trasformata viene limitata ponendo a $-\infty$ i valori esterni all'area considerata. Infine, i bordi di separazione ottenuti vengono rimossi e viene selezionata esclusivamente la componente connessa contenente il seme iniziale, ovvero la regione tumorale.

Risultati intermedi della segmentazione Per ciascuna configurazione analizzata, viene salvata una figura che riassume i passaggi della pipeline, tra cui la maschera ottenuta con *Otsu* (in giallo), l'espansione del *Region Growing* (in ciano), il risultato del *Watershed* (in magenta) e la maschera finale non rifinita (in rosso), come riportato di seguito.

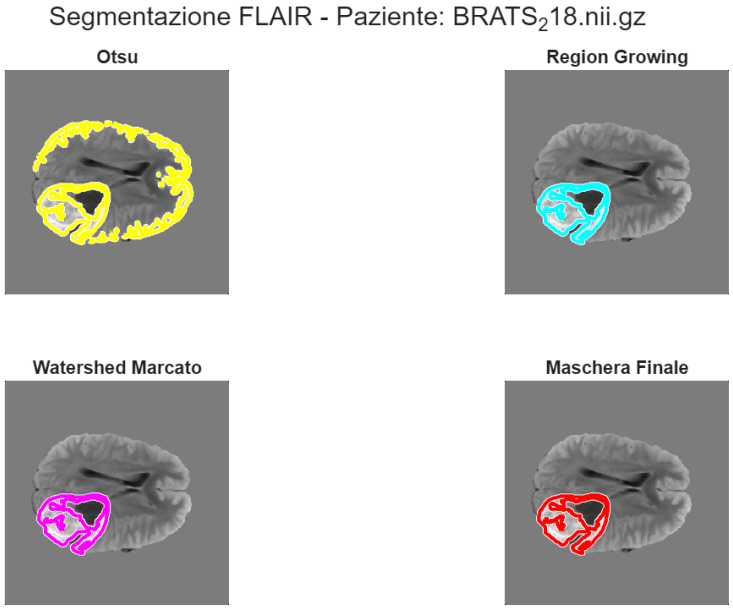

Figura 3.14: Risultati intermedi della segmentazione sulla sequenza *FLAIR*.

Nella Figura 3.14, la segmentazione iniziale ottenuta con *Otsu* risulta ampia e con regioni spurie lungo la periferia cerebrale. Il *Region Growing* consente di selezionare la componente connessa più pertinente attorno al seme, mentre il *Marker-Controlled Watershed* ne rifinisce il contorno.

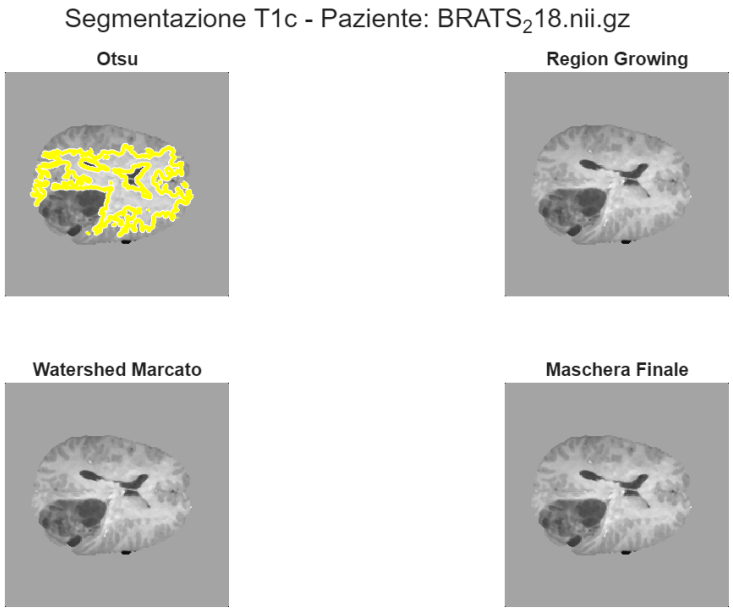

Figura 3.15: Risultati intermedi della segmentazione sulla sequenza *T1c*.

Nel caso della sequenza *T1c* in Figura 3.15, la sogliatura di *Otsu* individua diverse regioni ad alta intensità distribuite nell'immagine, che non risultano sufficientemente connesse con l'intera estensione della lesione. Di conseguenza, le successive fasi di *Region Growing* e *Marker-Controlled Watershed* non riescono a produrre una segmentazione significativa.

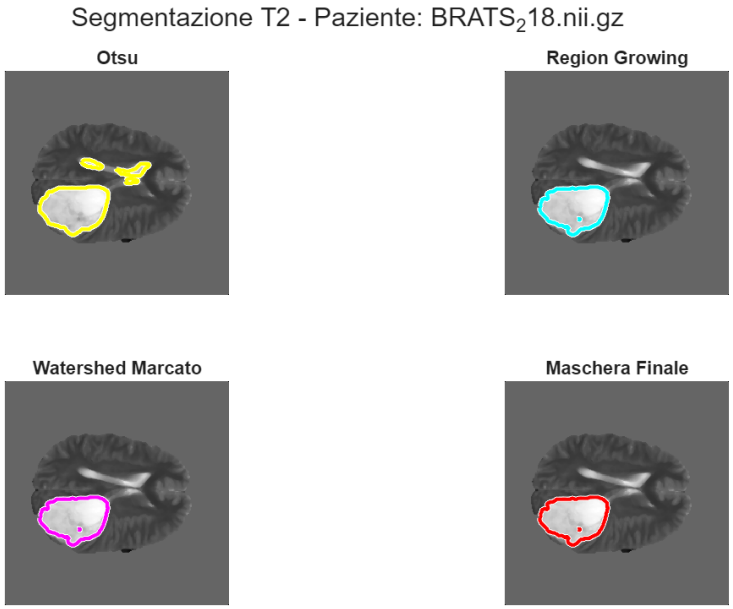

Figura 3.16: Risultati intermedi della segmentazione sulla sequenza *T2*.

Per la sequenza *T2* riportata in Figura 3.16, la sogliatura di *Otsu* riesce a individuare la regione tumorale, ma considera alcune aree secondarie errate.

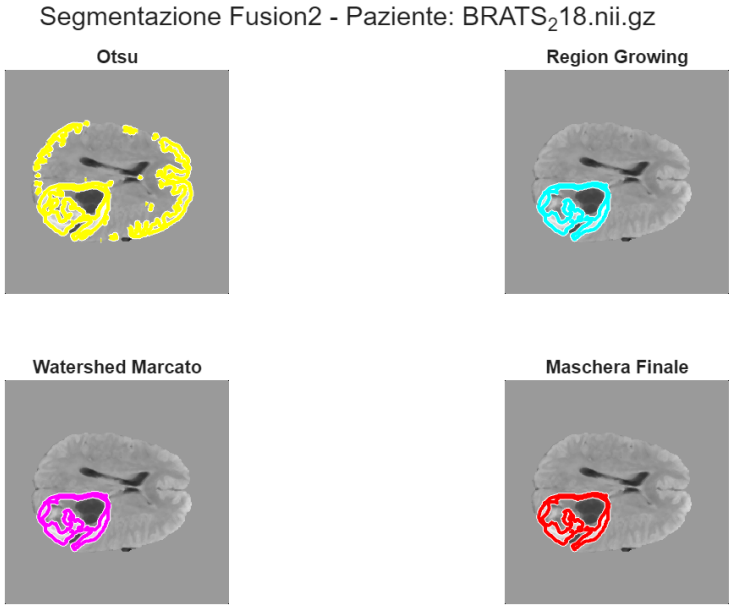

Figura 3.17: Risultati intermedi della segmentazione sulla rappresentazione bimodale.

Nel caso della rappresentazione bimodale in Figura 3.17, la sogliatura di *Otsu* opera come nel caso precedente, sebbene in misura più contenuta rispetto alla sequenza *FLAIR*.

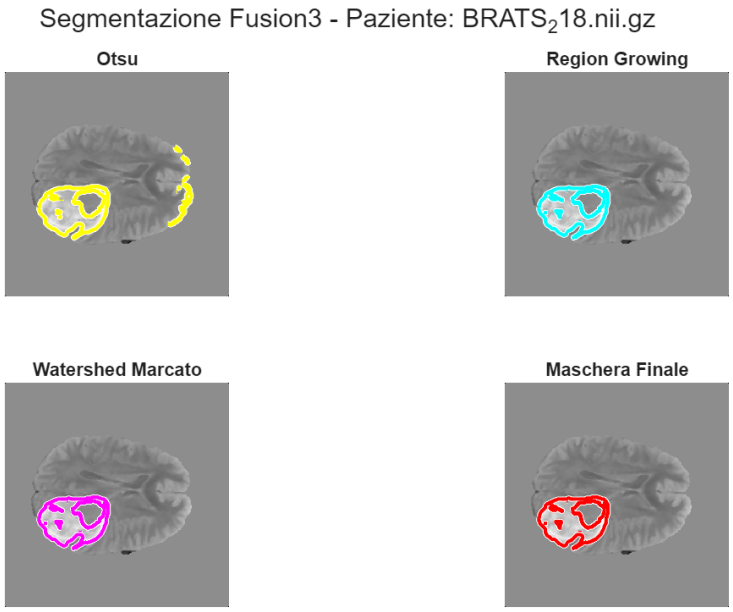

Figura 3.18: Risultati intermedi della segmentazione sulla rappresentazione multimodale.

Nel caso della rappresentazione multimodale in Figura 3.18, la sogliatura iniziale di *Otsu* risulta già più selettiva rispetto alle altre configurazioni, concentrandosi maggiormente sulla regione tumorale rispetto alle zone periferiche.

Pertanto, tale maschera finale appare la più equilibrata tra estensione della lesione e regolarità del contorno grazie alla combinazione delle tre sequenze.

3.2.5 Post-Processing

La fase di post-processing rifinisce le maschere binarie ottenute dalla segmentazione, correggendo le irregolarità dei contorni e rimuovendo componenti residue. Le operazioni sono implementate nel modulo *post_processing.m*, che riceve in ingresso la maschera grezza, l'immagine preprocessata da utilizzare come sfondo per la visualizzazione, il nome della sequenza e l'identificativo del paziente.

Inizialmente, viene creata la cartella per il salvataggio dei risultati di post-processing per il paziente corrente. Successivamente, viene definito un elemento strutturante morfologico di forma circolare tramite la funzione *strel("disk", 3)*.

Chiusura morfologica La prima operazione applicata alla maschera grezza è la chiusura morfologica con la funzione *imclose*. La chiusura consiste in una dilatazione e un'erosione eseguite con lo stesso elemento strutturante. Indicando con M_{raw} la maschera binaria in ingresso e con B l'elemento strutturante, la chiusura può essere espressa come:

$$M_{\text{close}} = (M_{\text{raw}} \oplus B) \ominus B$$

dove $\oplus$ indica la dilatazione e $\ominus$ l'erosione.

La dilatazione espande temporaneamente i contorni della regione segmentata, colmando piccole discontinuità, mentre l'erosione riduce la regione riportandola a dimensioni simili a quelle originali.

Riempimento delle cavità Dopo la chiusura morfologica, si applica la funzione *imfill(mask_clean, "holes")* per riempire le cavità interne alla maschera, ovvero le regioni di pixel di sfondo circondate da pixel appartenenti all'oggetto segmentato. Esse vengono convertite in pixel dell'oggetto senza modificare lo sfondo esterno alla maschera.

Selezione della componente connessa principale L'ultima operazione consiste nell'applicazione della funzione *bwareafilt(mask_clean, 1)*, che preserva la componente connessa di area maggiore (il parametro 1 indica una sola componente).

La funzione analizza tutte le componenti connesse presenti nella maschera, calcola l'area in base al numero di pixel e seleziona soltanto quella più estesa.

Risultati grafici Per ogni configurazione, il modulo genera una figura di confronto tra la maschera grezza di segmentazione e la maschera finale dopo il post-processing. In entrambi i casi, il contorno della regione segmentata viene sovrapposto all'immagine preprocessata con la funzione *visboundaries*.

Di seguito, si riportano i risultati nelle Figure 3.19, 3.20, 3.21, 3.22 e 3.23.

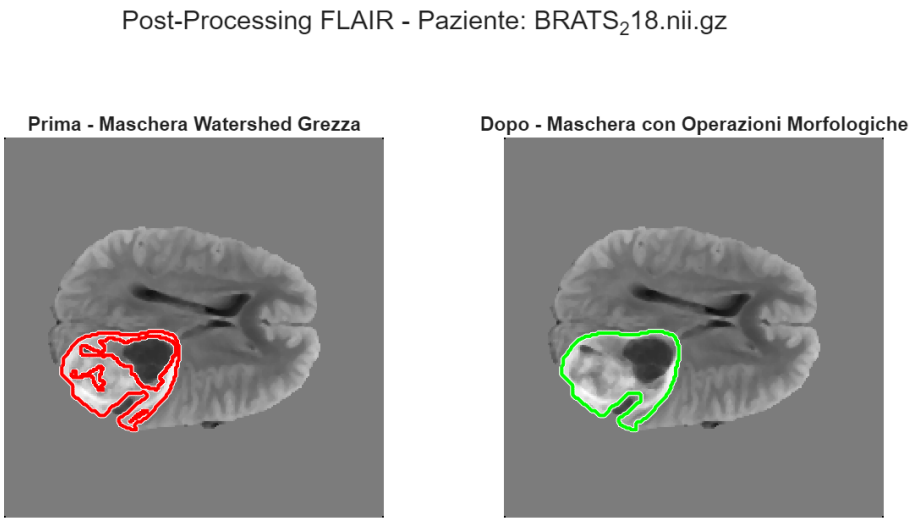

Figura 3.19: Confronto tra maschera grezza e maschera raffinata dopo post-processing per la sequenza *FLAIR*.

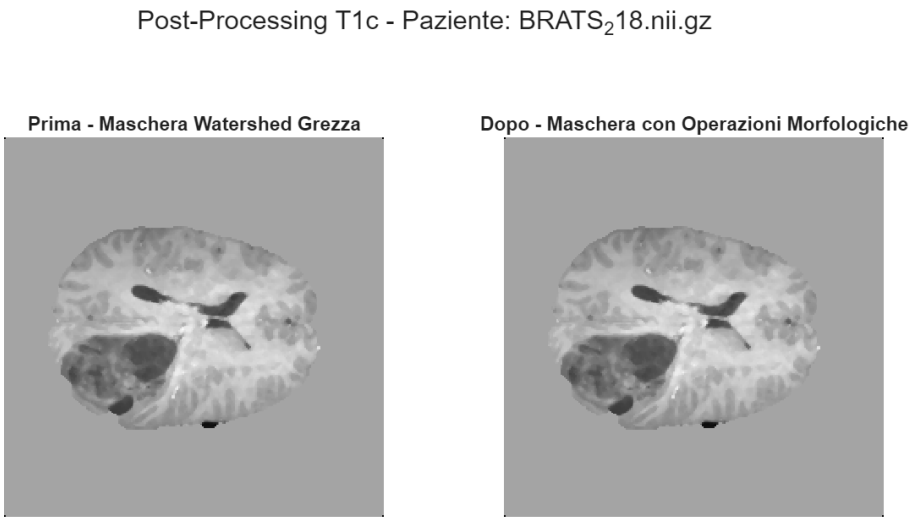

Figura 3.20: Confronto tra maschera grezza e maschera raffinata dopo post-processing per la sequenza *T1c*.

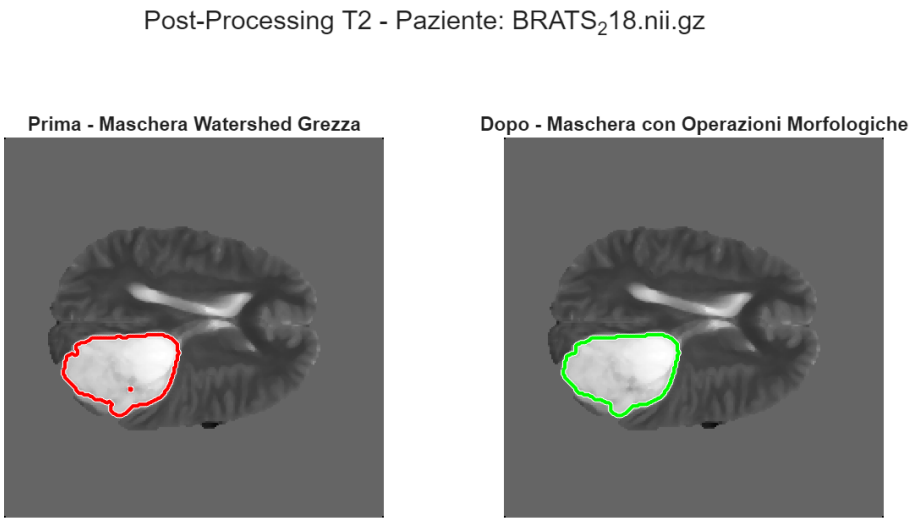

Figura 3.21: Confronto tra maschera grezza e maschera raffinata dopo post-processing per la sequenza *T2*.

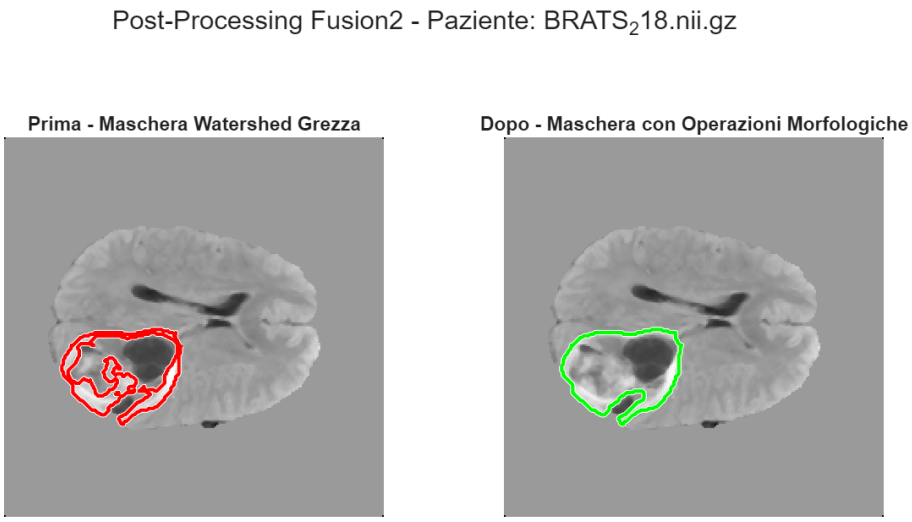

Figura 3.22: Confronto tra maschera grezza e maschera raffinata dopo post-processing per la rappresentazione bimodale.

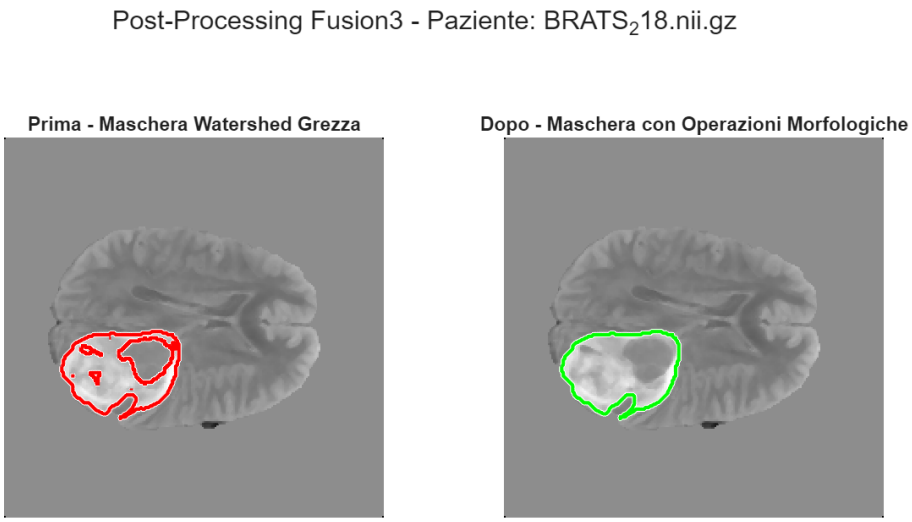

Figura 3.23: Confronto tra maschera grezza e maschera raffinata dopo post-processing per la rappresentazione multimodale.

Nelle configurazioni *FLAIR*, *Fusion2* e *Fusion3* si osserva l'effettivo riempimento delle cavità interne e una maggiore continuità del bordo, mentre nella *T2* l'intervento risulta più contenuto, poiché la maschera grezza appare già compatta. Nel caso della *T1c*, invece, il post-processing non compensa l'assenza di una segmentazione efficace.

3.2.6 Valutazione

L'ultima fase della pipeline riguarda la valutazione delle maschere di segmentazione ottenute. Tale operazione è implementata nella funzione *evaluation.m*, che confronta la sovrapposizione della maschera binaria predetta con la corrispondente *ground truth* binaria.

Le metriche ottenute per i singoli pazienti e per l'intero dataset vengono memorizzate in due file CSV. In particolare, vengono calcolate tre metriche standard:

- **Dice Score**: fornisce una misura complessiva della qualità della sovrapposizione, poiché tiene conto sia dei falsi positivi che dei falsi negativi;
- **Sensitivity**: evidenzia la capacità di recuperare la regione tumorale reale;
- **Precision**: misura il contenimento delle regioni spurie e dei falsi positivi.

La funzione riceve in ingresso due maschere binarie, corrispondenti alla segmentazione predetta dalla pipeline (*mask_pred*) e alla *ground truth* di riferimento (*mask_gt*). Entrambe le maschere vengono interpretate come immagini binarie della stessa dimensione, in cui i pixel appartenenti alla regione tumorale assumono valore logico vero, mentre i pixel di sfondo assumono valore falso.

Il primo passo consiste nel calcolo a livello di pixel di:

- **True Positive (TP)**: pixel correttamente classificati come tumore;
- **False Positive (FP)**: pixel classificati come tumore dalla predizione, ma assenti nella *ground truth*;
- **False Negative (FN)**: pixel appartenenti alla *ground truth* tumorale, ma non rilevati dalla segmentazione.

Tali quantità vengono ottenute mediante operazioni logiche elemento per elemento tra le due maschere:

$$TP = \sum \left(mask_{\text{pred}} \wedge mask_{\text{gt}} \right)$$
$$FP = \sum \left(mask_{\text{pred}} \wedge \neg mask_{\text{gt}} \right)$$
$$FN = \sum \left(\neg mask_{\text{pred}} \wedge mask_{\text{gt}} \right)$$

dove il simbolo $\wedge$ indica l'operatore logico AND e $\neg$ la negazione logica.

Dice Score La prima metrica calcolata è il *Dice Score*, che rappresenta una misura di similarità spaziale tra la segmentazione predetta e la *ground truth*. Esso è definito come:

$$Dice = \frac{2TP}{2TP + FP + FN}$$

Il *Dice Score* assume valori compresi tra 0 e 1. Un valore pari a 1 indica una sovrapposizione perfetta tra maschera predetta e *ground truth*, mentre un valore pari a 0 indica assenza totale di sovrapposizione.

Sensitivity La seconda metrica è la *Sensitivity*, nota anche come *Recall*, che misura la capacità dell'algoritmo di individuare correttamente i pixel tumorali realmente presenti nella *ground truth*:

$$Sensitivity = \frac{TP}{TP + FN}$$

Anche questa metrica varia tra 0 e 1. Un valore elevato indica che la pipeline riesce a rilevare gran parte della lesione, riducendo i falsi negativi. Un valore basso corrisponde alla mancata identificazione di porzioni tumorali effettivamente presenti.

Precision La terza metrica è la *Precision*, che misura la quota di pixel classificati come tumore che risultano realmente corretti:

$$Precision = \frac{TP}{TP + FP}$$

Un valore elevato indica che la segmentazione introduce pochi falsi positivi, ovvero poche aree etichettate in modo errato.

L'uso congiunto di queste metriche consente un'interpretazione completa dei risultati della pipeline. Ad esempio, una segmentazione può ottenere una *Sensitivity* elevata ma una *Precision* bassa, indicando una buona capacità di individuare il tumore, ma con una maschera più estesa del necessario. Viceversa, una *Precision* elevata associata a una *Sensitivity* ridotta suggerisce una segmentazione più selettiva, ma incapace di includere l'intera area della lesione.

Capitolo 4

Risultati

In questo capitolo vengono analizzati i risultati ottenuti dall'esecuzione della pipeline. L'impiego di casi rappresentativi facilita la comprensione dei fenomeni alla base del successo o del fallimento delle segmentazioni.

4.1 Analisi delle Metriche

Al fine di analizzare le metriche medie aggregate sull'intero dataset, si considerano i valori riportati nel file *global.csv*, presentati nella Tabella 4.1.

Tabella 4.1: Metriche medie aggregate sull'intero dataset per le cinque configurazioni sperimentali analizzate.

Sequenza	**Dice Score medio**	**Sensitivity media**	**Precision media**
FLAIR	0.795	0.765	0.900
T1c	0.195	0.178	0.886
T2	0.520	0.428	0.893
Fusion2	0.755	0.767	0.842
Fusion3	0.806	0.744	0.935

È possibile notare come la configurazione *Fusion3* (*FLAIR*+T1c+*T2*) ottenga le migliori prestazioni complessive, con valori medi pari a *Dice Score* = 0.806, *Sensitivity* = 0.744 e *Precision* = 0.935. La seconda configurazione più efficace risulta essere *FLAIR*, con *Dice* medio pari a 0.795, seguita da *Fusion2* con *Dice* medio pari a 0.755. La sequenza *T2*, invece, presenta prestazioni inferiori con *Dice* medio pari a 0.520, mentre la *T1c* è la configurazione meno affidabile in singolo, con *Dice* medio pari a 0.195.

Nel complesso, i risultati confermano che la fusione multimodale, e in particolare quella trimodale adottata in *Fusion3*, rappresenta la soluzione migliore tra quelle analizzate.

4.2 Analisi dei Casi Rappresentativi

Sono stati selezionati alcuni casi studio a partire dal file *detailed.csv*, individuando i due dei migliori casi e due dei peggiori casi in termini di *Dice Score* sulla

configurazione *Fusion3*, come presentato in Tabella 4.2.

Tabella 4.2: Valori di *Dice Score* ottenuti nei casi rappresentativi individuati per le cinque configurazioni sperimentali.

Paziente	**FLAIR**	**T1c**	**T2**	**Fusion2**	**Fusion3**
BRATS_128.nii.gz	0.879	0.048	0.645	0.318	0.963
BRATS_248.nii.gz	0.974	0.534	0.396	0.967	0.963
BRATS_140.nii.gz	0.271	0.000	0.002	0.680	0.000
BRATS_380.nii.gz	0.000	0.000	0.000	0.000	0.000

4.2.1 Casi Migliori

BRATS_128.nii.gz Rappresenta uno dei migliori risultati ottenuti dalla pipeline, con *Dice Score* pari a 0.963 sulla configurazione *Fusion3*.

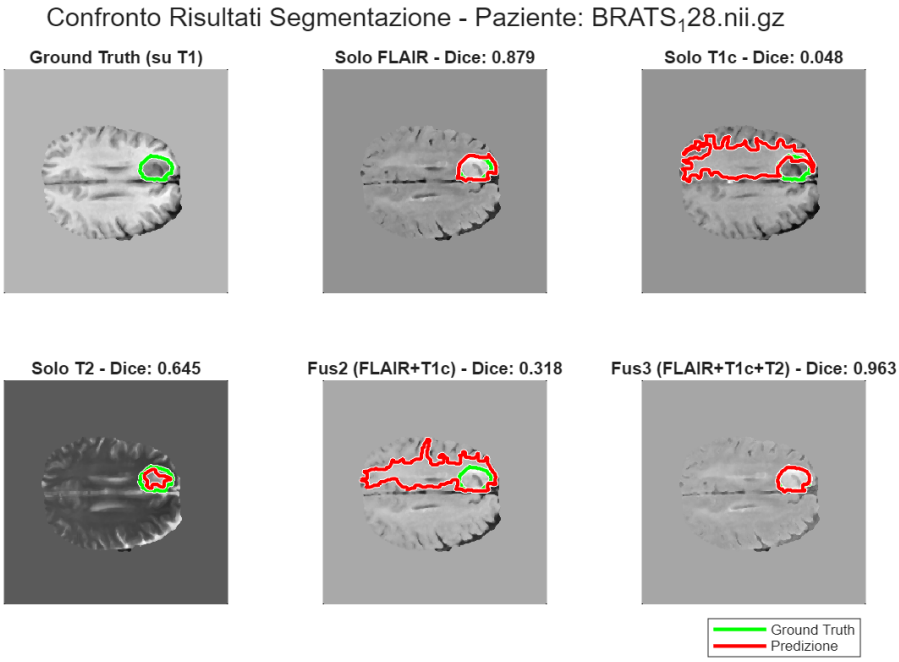

Figura 4.1: Confronto finale dei risultati di segmentazione per il paziente 128.

Dalla Figura 4.1 si osserva che la segmentazione ottenuta con *Fusion3* presenta una sovrapposizione quasi completa con la *ground truth*, seguendo con buona precisione la forma della lesione.

Inizialmente, la lesione appare distinta dal tessuto circostante nella rappresentazione multimodale, facilitando la fase iniziale di sogliatura con Otsu. In questo caso, la combinazione tra *FLAIR* e *T2* valorizza l'estensione della lesione, mentre il contributo ambiguo della *T1c* viene attenuato dalla presenza delle altre modalità. Di conseguenza, la maschera generata su *Fusion3* risulta più vicina alla reale distribuzione del tumore rispetto a *Fusion2*.

Inoltre, la *seed map* costruita sulla fusione multimodale localizza il seme in una regione interna alla lesione. Questo rende più efficace il *Region Growing*, che può espandersi in una zona coerente dal punto di vista dell'intensità e della continuità

spaziale. Il *Marker-Controlled Watershed* riesce, quindi, a rifinire il contorno senza alterazioni.

Anche la sola sequenza *FLAIR* fornisce un buon risultato, con *Dice* pari a 0.879, mentre la *T2* raggiunge una prestazione intermedia (0.645). Al contrario, la *T1c* risulta inadeguata, con *Dice* pari a 0.048, poiché produce una segmentazione estesa lungo una fascia orizzontale dell'immagine. Anche *Fusion2* risente di questo comportamento anomalo della *T1c* e ottiene un *Dice* molto basso (0.318).

BRATS_248.nii.gz Mostra una prestazione eccellente, con *Dice Score* pari a 0.963 sulla configurazione *Fusion3*.

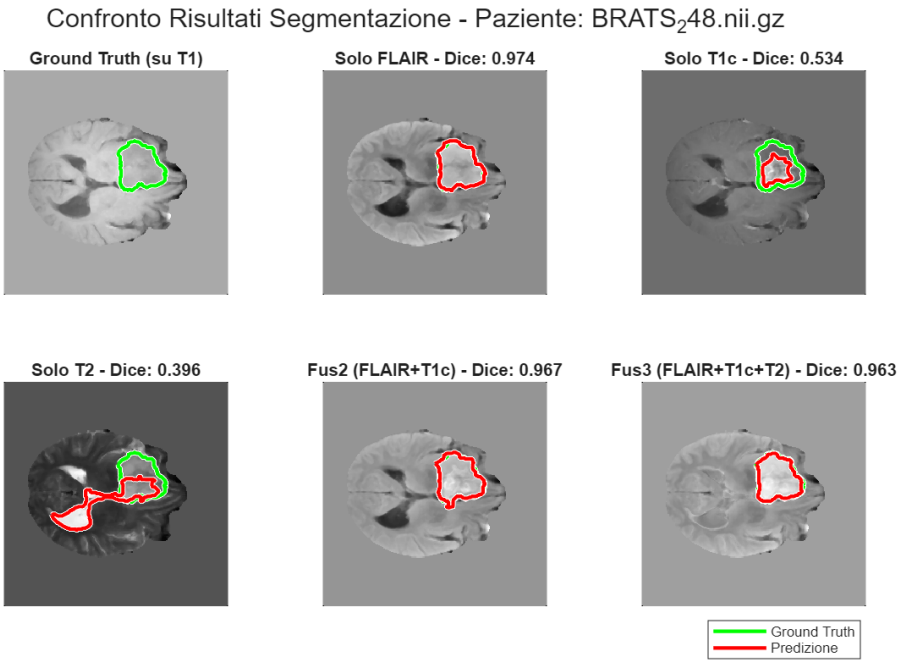

Figura 4.2: Confronto finale dei risultati di segmentazione per il paziente 248.

Come evidenziato in Figura 4.2, la lesione presenta una forma compatta e distinguibile dalle zone circostanti. In tal caso *FLAIR*, *Fusion2* e *Fusion3* riescono a produrre buone segmentazioni. La *FLAIR* raggiunge un *Dice* pari a 0.974, superiore anche alla fusione trimodale, mentre *Fusion2* ottiene 0.967 e *Fusion3* 0.963.

Il motivo di queste prestazioni elevate risiede nel fatto che, nel paziente considerato, la lesione è ben rappresentata nella sequenza *FLAIR* e, dunque, la sogliatura con Otsu riesce a individuare una regione iniziale già molto vicina alla *ground truth*. Il *Region Growing* si sviluppa, dunque, attorno a un seme ottimale e il *Marker-Controlled Watershed* beneficia dei contorni regolari e continui del tumore.

Le modalità *T1c* e *T2*, se considerate singolarmente, risultano meno efficaci. La *T1c* produce una segmentazione più contenuta rispetto alla *ground truth*, mentre la *T2* introduce regioni non coerenti con l'estensione reale della lesione. Tuttavia, quando le informazioni vengono combinate nella fusione multimodale, non compromettono il risultato complessivo.

4.2.2 Casi Peggiori

BRATS_140.nii.gz Rappresenta uno degli esempi più critici della pipeline, con *Dice Score* pari a 0.000 sulla configurazione *Fusion3*.

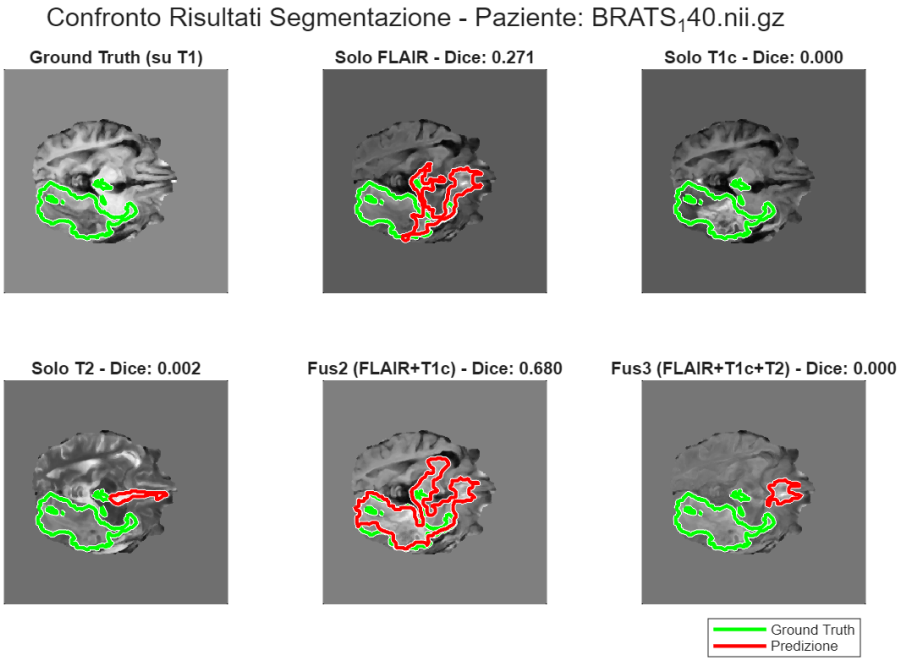

Figura 4.3: Confronto finale dei risultati di segmentazione per il paziente 140.

Dalla Figura 4.3 si osserva che la *ground truth* occupa una regione ampia e irregolare a sinistra dell'immagine, mentre la segmentazione ottenuta con *Fusion3* viene localizzata in una zona spostata verso destra. Di conseguenza, non si verifica alcuna sovrapposizione tra predizione e riferimento e il *Dice Score* risulta nullo.

La *Fusion3* genera una distribuzione di intensità che non valorizza la lesione reale, ma una regione differente dell'immagine. Ciò influisce sulla fase di sogliatura con Otsu, che produce una maschera preliminare non coerente con la posizione del tumore. Di conseguenza, anche la *seed map* tende a individuare un seme iniziale in una zona non pertinente.

Selezionando un seme errato, l'intera fase di *Region Growing* si sviluppa attorno a una regione sbagliata. Il *Marker-Controlled Watershed* non è in grado di correggere un errore di localizzazione così marcato, poiché lavora sulla maschera preliminare costruita nelle fasi precedenti. Il post-processing morfologico può soltanto regolarizzare la maschera prodotta, ma non recuperarne la posizione corretta.

Anche le altre modalità mostrano un comportamento problematico. La *T1c* fallisce completamente, mentre la *T2* individua una piccola regione errata. La *FLAIR* riesce a intercettare parzialmente la lesione, ma con una segmentazione frammentata. È interessante notare che *Fusion2* ottiene, invece, un risultato poco migliore (0.680), in quanto l'aggiunta della *T2* nella fusione multimodale introduce un'informazione ambigua che altera la localizzazione corretta della regione tumorale.

BRATS_380.nii.gz Un ulteriore caso di fallimento completo è rappresentato dal paziente *BRATS_380.nii.gz*, per il quale tutte le configurazioni principali mostrano *Dice Score* pari a 0.000.

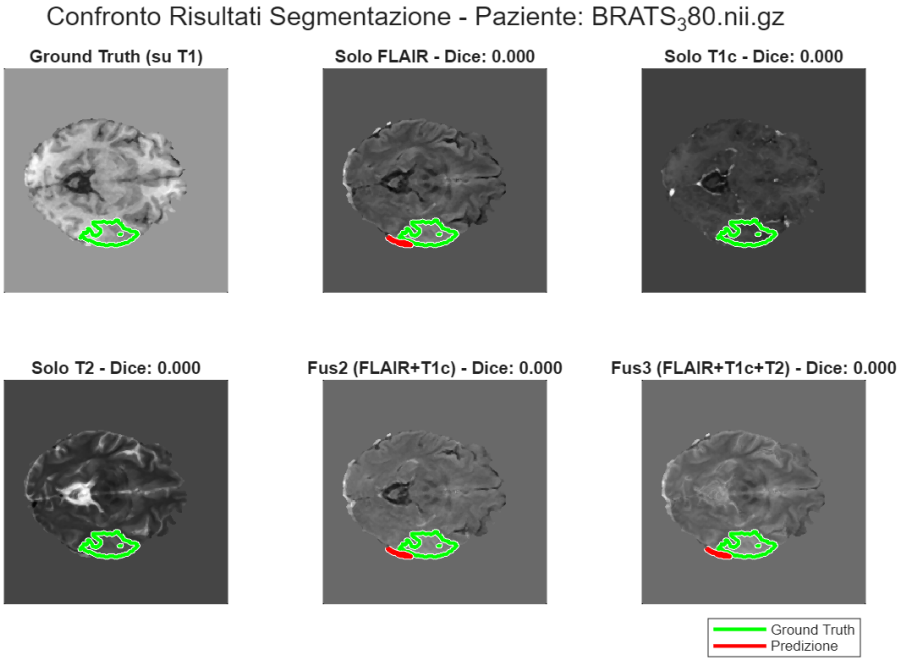

Figura 4.4: Confronto finale dei risultati di segmentazione per il paziente 380.

Come mostrato in Figura 4.4, la *ground truth* è posizionata in una piccola regione nella parte inferiore dell'immagine, mentre le predizioni prodotte dalla pipeline risultano assenti oppure collocate lateralmente. In nessun caso si realizza una sovrapposizione sufficiente con la *ground truth*.

Il fallimento è dovuto alle caratteristiche intrinseche della lesione, che appare piccola e poco evidente rispetto al contesto circostante. Una configurazione di questo tipo rende complicata la fase di sogliatura iniziale, poiché il tumore e il tessuto sano non presentano livelli di intensità nettamente separabili nell'istogramma. Inoltre, anche la generazione della *seed map* diventa meno affidabile, dato che la sfocatura gaussiana privilegia aree a intensità più marcata che non coincidono con una lesione piccola e poco contrastata.

Capitolo 5

Conclusioni

La pipeline proposta per la segmentazione di tumori cerebrali in immagini MRI, basata su tecniche classiche di *Image Processing*, ha mostrato le migliori prestazioni medie nella configurazione *Fusion3*.

Nel complesso, è stato valutato come l'utilizzo di tecniche tradizionali di segmentazione possano fornire risultati significativi, nonostante l'adozione predominante di tecniche di *Deep Learning* e Reti Neurali Convoluzionali (CNN) come stato dell'arte attuale.

5.1 Limiti Strutturali

L'analisi dei casi migliori ha mostrato che la pipeline funziona bene quando la lesione presenta una morfologia compatta e un contrasto netto rispetto al tessuto circostante. In tali condizioni, la combinazione delle diverse modalità consente di ottenere contorni aderenti alla *ground truth* e di limitare la presenza di falsi positivi.

Al contrario, i casi peggiori hanno messo in evidenza alcune fragilità del metodo. In particolare, la multimodalità, pur essendo mediamente vantaggiosa, non garantisce automaticamente un miglioramento in ogni paziente, poiché se una delle sequenze contribuisce in modo non coerente alla rappresentazione finale, essa può influenzare negativamente la sogliatura iniziale, la scelta del seme e l'intera segmentazione.

5.2 Sviluppi Futuri

Tra gli sviluppi futuri, è possibile valutare strategie di fusione multimodale più avanzate rispetto alla combinazione lineare pesata, così da valorizzare il contributo delle diverse sequenze MRI.

Inoltre, sarebbe opportuno passare da una segmentazione bidimensionale basata sulle singole *slice* a un approccio tridimensionale sull'intero volume MRI, per sfruttare in modo più completo la continuità della lesione.

Infine, si potrebbero confrontare le tecniche adottate in questo lavoro con altri metodi classici di Image Processing, al fine di valutarne vantaggi, limiti e possibili integrazioni rispetto alla soluzione proposta. Per lo scopo, si citano le seguenti alternative.

5.2.1 K-Means

A differenza dell'approccio implementato, che segmenta la lesione attraverso fasi sequenziali, il *K-Means* suddivide i pixel in un numero prefissato di classi sulla base della similarità delle intensità. Concettualmente, vi è un'analogia con la sogliatura multilivello di Otsu, poiché in entrambi i casi si ottiene una partizione dell'immagine in regioni differenti. Tuttavia, Otsu sfrutta la distribuzione dell'istogramma per determinare soglie ottimali, mentre K-Means opera iterativamente per assegnare i centroidi e aggiornare i cluster.

5.2.2 Metodi Edge-Based

Gli approcci *Edge-Based* si basano sull'individuazione dei contorni nell'immagine, non sulla crescita di regioni omogenee.

Essi differiscono da quanto proposto nel lavoro presentato, in quanto la segmentazione viene costruita progressivamente a partire da una regione iniziale e una soglia, mentre gli approcci edge-based identificano direttamente le discontinuità locali di intensità che delimitano la lesione.

In maniera simile, il *Marker-Controlled Watershed* è influenzato dalla struttura dei contorni. Nelle immagini tumorali in MRI i bordi della lesione sono irregolari e sfumati, rendendo le tecniche edge-based meno stabili rispetto a un approccio *Region-Based* come quello adottato.

Tra gli operatori di rilevazione dei bordi più noti si citano *Sobel* e *Canny*. Il primo stima il gradiente locale dell'immagine mediante maschere convoluzionali orientate, mettendo in evidenza le variazioni brusche di intensità. Un possibile utilizzo sarebbe quello di evidenziare i margini principali della lesione prima della fase di rifinitura. Presenta, però, una maggiore sensibilità al rumore e tende a produrre contorni spessi e non sempre chiusi.

Il secondo è più sofisticato e migliora il processo attraverso una fase di sfocatura gaussiana, il calcolo del gradiente, la soppressione dei non-massimi e una sogliatura. Rispetto a Sobel, produce contorni più sottili e continui, ma individua prevalentemente i bordi locali e non costruisce direttamente una regione segmentata.

Bibliografia

[1] M. Antonelli, A. Reinke, S. Bakas, K. Farahani, A. Kopp-Schneider, B. A. Landman, G. Litjens, B. H. Menze, O. Ronneberger, R. M. Summers, B. van Ginneken, *et al.*, "The medical segmentation decathlon," *Nature Communications*, vol. 13, no. 1, p. 4128, 2022.

[2] B. H. Menze, A. Jakab, S. Bauer, J. Kalpathy-Cramer, K. Farahani, J. Kirby, Y. Burren, N. Porz, J. Slotboom, R. Wiest, *et al.*, "The multimodal brain tumor image segmentation benchmark (brats)," *IEEE Transactions on Medical Imaging*, vol. 34, no. 10, pp. 1993–2024, 2015.

[3] A. P. James and B. V. Dasarathy, "Medical image fusion: A survey of the state of the art," *Information Fusion*, vol. 19, pp. 4–19, 2014. Special Issue on Information Fusion in Medical Image Computing and Systems.

[4] Z. Peter, V. Bousson, C. Bergot, and F. Peyrin, "A constrained region growing approach based on watershed for the segmentation of low contrast structures in bone micro-ct images," *Pattern Recognition*, vol. 41, no. 7, pp. 2358–2368, 2008.

[5] The MathWorks, Inc., "MATLAB and Image Processing Toolbox Release 2025b," 2025. Disponibile su https://www.mathworks.com, consultato il 24 marzo 2026.

[6] N. Otsu, "A threshold selection method from gray-level histograms," *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 9, no. 1, pp. 62–66, 1979.

[7] R. Adams and L. Bischof, "Seeded region growing," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 16, no. 6, pp. 641–647, 1994.

[8] L. Vincent and P. Soille, "Watersheds in digital spaces: an efficient algorithm based on immersion simulations," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 13, no. 6, pp. 583–598, 1991.

[9] A. Grau, A. U. Mewes, M. Alcaniz, R. Kikinis, and S. K. Warfield, "Improved watershed transform for medical image segmentation using prior information," *IEEE Transactions on Medical Imaging*, vol. 23, no. 4, pp. 447–458, 2004.